



---

# Analyse FMDS et Maintenance Prédicative des machines industrielles

---

**Réalisé par :** Rouweida Laaroussi

Sahar lahbib

**Encadré par :** Faycel ben hmida

Année 2025/2026

## Sommaire

|                                                                    |    |
|--------------------------------------------------------------------|----|
| Sommaire.....                                                      | 0  |
| Liste des Figures.....                                             | 3  |
| Introduction Générale.....                                         | 4  |
| Chapitre 1 : Description du Système Industriel.....                | 5  |
| 1.1 Introduction.....                                              | 5  |
| 1.2 Problématique.....                                             | 5  |
| 1.3 Solutions Proposées.....                                       | 5  |
| 1.4 Description Fonctionnelle de la Machine Industrielle.....      | 5  |
| 1.5 Modes de Défaillance du Système.....                           | 5  |
| Effets des défaillances.....                                       | 6  |
| 1.6 Données Utilisées – Structure du Dataset.....                  | 6  |
| Tableau des données et des défaillances.....                       | 7  |
| 1.7 Analyse Exploratoire des Capteurs.....                         | 7  |
| Chapitre 2 : Simulation des Données et Modèles Statistiques.....   | 10 |
| 2.1 Principe de Simulation.....                                    | 10 |
| 2.2 Censure des Données.....                                       | 10 |
| 2.3 Lois Statistiques de Défaillance.....                          | 10 |
| 2.4 Interprétation.....                                            | 11 |
| 2.5 Approche PHM (Prognostics and Health Management).....          | 11 |
| Chapitre 3 : Analyse FMDS.....                                     | 12 |
| 3.1 Définition des Indicateurs FMDS.....                           | 12 |
| 3.2 Formules et Calcul des Indicateurs.....                        | 12 |
| 3.3 Méthodologie Appliquée.....                                    | 12 |
| 3.4 Résultats Obtenus – Python.....                                | 12 |
| 3.5 Résultats Obtenus – MATLAB.....                                | 13 |
| 3.6 Interprétation des Résultats.....                              | 14 |
| Chapitre 4 : Analyse de Survie.....                                | 15 |
| 4.1 Méthodes Non Paramétriques.....                                | 15 |
| 4.2 Modèle de Weibull – Analyse Paramétrique.....                  | 16 |
| 4.3 Interprétation du Modèle de Weibull.....                       | 17 |
| Chapitre 5 : Diagnostic des Défaillances par Machine Learning..... | 18 |
| 5.1 Objectif du Diagnostic.....                                    | 18 |
| 5.2 Modèles de Machine Learning Utilisés.....                      | 18 |
| Random Forest Classifier.....                                      | 18 |
| Decision Tree.....                                                 | 18 |

|                                                                      |    |
|----------------------------------------------------------------------|----|
| Support Vector Machine (SVM) .....                                   | 18 |
| 5.3 Résultats des Modèles – Python .....                             | 18 |
| 5.4 Résultats – MATLAB.....                                          | 19 |
| 5.5 Analyse de l'Importance des Variables (Feature Importance) ..... | 20 |
| 5.6 Interprétation des Résultats .....                               | 21 |
| Chapitre 6 : Pronostic de la Durée de Vie Résiduelle (RUL) .....     | 22 |
| 6.1 Introduction au Pronostic .....                                  | 22 |
| 6.2 Modèle Utilisé – XGBoost Regressor .....                         | 22 |
| 6.3 Méthodologie .....                                               | 22 |
| 6.4 Résultats Obtenus .....                                          | 22 |
| 6.5 Interprétation des Résultats .....                               | 23 |
| 6.6 Importance Industrielle du Pronostic RUL .....                   | 23 |
| Conclusion Générale .....                                            | 25 |
| 26                                                                   |    |

## Liste des Figures

|                  |                                                                                |
|------------------|--------------------------------------------------------------------------------|
| <b>Figure 1</b>  | Distribution de la température de l'air [K] en fonction de l'état de panne     |
| <b>Figure 2</b>  | Distribution de la vitesse de rotation [rpm] en fonction de l'état de panne    |
| <b>Figure 3</b>  | Distribution du couple [Nm] en fonction de l'état de panne                     |
| <b>Figure 4</b>  | Distribution de la température de processus [K] en fonction de l'état de panne |
| <b>Figure 5</b>  | Distribution de la température de l'air [K] – vue complémentaire               |
| <b>Figure 6</b>  | Modèle de Weibull – Fonction de fiabilité                                      |
| <b>Figure 7</b>  | Loi Exponentielle – Taux de défaillance constant                               |
| <b>Figure 8</b>  | Loi Log-normale – Dégradation progressive                                      |
| <b>Figure 9</b>  | Loi Gamma – Sollicitations cumulatives                                         |
| <b>Figure 10</b> | Indicateurs FMDS – Représentation graphique (Python)                           |
| <b>Figure 11</b> | Indicateurs FMDS – Résultats obtenus sous MATLAB                               |
| <b>Figure 12</b> | Résultats du modèle SVM – Rapport de classification                            |
| <b>Figure 13</b> | Matrice de confusion – Random Forest Classifier                                |
| <b>Figure 14</b> | Importance des variables – Random Forest (Python)                              |
| <b>Figure 15</b> | Matrice de confusion – Modèle de classification MATLAB                         |
| <b>Figure 16</b> | Scores d'importance des variables (Python – Random Forest)                     |
| <b>Figure 17</b> | Graphique d'importance des variables – Random Forest                           |
| <b>Figure 18</b> | Courbe de fiabilité – Estimateur de Kaplan-Meier                               |
| <b>Figure 19</b> | Fonction de survie – Modèle de Weibull                                         |
| <b>Figure 20</b> | Risque cumulatif – Estimateur de Nelson-Aalen                                  |
| <b>Figure 21</b> | Paramètres du modèle de Weibull (Lambda et Rho)                                |
| <b>Figure 22</b> | RUL réel vs RUL prédit – Modèle XGBoost Regressor                              |

## Introduction Générale

Avec l'émergence de l'Industrie 4.0, les systèmes industriels connaissent une transformation majeure basée sur l'intégration des technologies numériques, de l'Internet des objets (IoT) et de l'intelligence artificielle. Cette évolution a profondément modifié les stratégies de maintenance, faisant de la maintenance prédictive une solution innovante pour améliorer la performance et la fiabilité des équipements industriels.

Contrairement à la maintenance curative, qui intervient après l'apparition d'une panne, et à la maintenance préventive, basée sur des interventions périodiques, la maintenance prédictive repose sur l'analyse en temps réel des données issues des capteurs afin d'anticiper les défaillances avant qu'elles ne surviennent. Cette approche permet de réduire les arrêts imprévus, d'optimiser les coûts de maintenance et d'augmenter la durée de vie des équipements.

Dans ce contexte, l'analyse FMDS (Fiabilité, Maintenabilité, Disponibilité et Sécurité) constitue un outil essentiel pour évaluer les performances des systèmes industriels et identifier les composants critiques. Associée aux techniques de traitement de données et aux algorithmes de machine learning, elle permet d'améliorer la prise de décision et d'estimer la durée de vie résiduelle des composants (RUL).

Ce projet s'inscrit dans cette démarche en exploitant des données industrielles issues de capteurs intelligents pour surveiller l'état de santé des équipements, détecter les anomalies et prédire les défaillances futures. L'objectif principal est de proposer une solution intelligente de maintenance prédictive capable d'améliorer la disponibilité des machines, de renforcer leur fiabilité et d'optimiser la gestion des interventions de maintenance.

# Chapitre 1 : Description du Système Industriel

## 1.1 Introduction

Dans le domaine industriel, les machines de production sont soumises à des conditions de fonctionnement continues qui provoquent progressivement leur dégradation. Des paramètres comme la température, la vitesse de rotation, le couple et l'usure des outils influencent directement leur état de santé. Une variation anormale de ces paramètres peut entraîner plusieurs types de défaillances, pouvant provoquer des arrêts imprévus de production et des coûts de maintenance élevés.

## 1.2 Problématique

Dans l'industrie moderne, l'exploitation des données issues des capteurs reste un défi important pour améliorer la maintenance des équipements. Malgré les progrès technologiques, il est encore difficile de détecter rapidement les défaillances, d'évaluer la performance des systèmes et d'estimer avec précision la durée de vie restante des machines.

Dans ce cadre, ce projet utilise le dataset AI4I 2020 Predictive Maintenance Dataset, qui contient des données industrielles telles que la température, la vitesse de rotation, le couple et l'usure des machines. La problématique centrale est la suivante :

***Comment exploiter ces données pour détecter les pannes, évaluer la fiabilité du système et prédire la durée de vie résiduelle (RUL) de manière efficace ?***

## 1.3 Solutions Proposées

Pour répondre à la problématique, plusieurs approches ont été mises en œuvre afin d'exploiter efficacement les données du dataset AI4I 2020 :

- Analyse des données et prétraitement : nettoyer et préparer les données issues des capteurs (température, vitesse de rotation, couple, usure) afin d'améliorer la qualité des résultats.
- Analyse FMDS : calculer des indicateurs de fiabilité, de disponibilité et de performance pour mieux comprendre le comportement global du système industriel.
- Diagnostic des défaillances : utiliser des algorithmes de classification (Random Forest, SVM, Decision Tree) pour distinguer les états normal et défaillant de la machine.
- Pronostic (RUL) : appliquer des modèles de régression et d'apprentissage automatique pour estimer la durée de vie résiduelle des équipements et anticiper les pannes.
- Maintenance prédictive intelligente : combiner ces différentes analyses pour mettre en place un système de détection d'anomalies et d'optimisation des interventions de maintenance.

## 1.4 Description Fonctionnelle de la Machine Industrielle

La machine industrielle étudiée dans ce projet est un système de production automatisé composé de plusieurs éléments essentiels : un moteur principal assurant la génération d'énergie mécanique, un système de transmission, un outil de coupe soumis à l'usure, ainsi qu'un système de contrôle garantissant la régulation des paramètres de fonctionnement. Le système est équipé de capteurs mesurant la température, la vitesse de rotation, le couple et l'usure de l'outil afin d'assurer une surveillance continue.

## 1.5 Modes de Défaillance du Système

Dans le cadre du dataset AI4I 2020, les principaux modes de défaillance identifiés sont :

| Code | Désignation              | Description                                                         |
|------|--------------------------|---------------------------------------------------------------------|
| TWF  | Tool Wear Failure        | Défaillance liée à l'usure excessive de l'outil de coupe            |
| HDF  | Heat Dissipation Failure | Défaillance thermique due à une mauvaise dissipation de chaleur     |
| OSF  | Overstrain Failure       | Surcharge mécanique dépassant les limites de contrainte             |
| PWF  | Power Failure            | Défaillance liée à une anomalie de puissance électrique             |
| RNF  | Random Failure           | Défaillance aléatoire indépendante des conditions de fonctionnement |

Ces défaillances sont directement liées aux conditions de fonctionnement de la machine (température, vitesse, couple et usure).

### Effets des défaillances

Ces défaillances peuvent entraîner les conséquences opérationnelles suivantes :

- Diminution des performances du système
- Arrêts non planifiés de la machine
- Risques de pannes critiques
- Augmentation des coûts de maintenance

## 1.6 Données Utilisées – Structure du Dataset

Les données utilisées dans ce projet proviennent du dataset AI4I 2020 Predictive Maintenance Dataset, qui représente le fonctionnement d'une machine industrielle à travers des mesures issues de capteurs. Le dataset est structuré sous forme de lignes représentant des cycles de fonctionnement. Chaque observation contient les variables suivantes :

- Conditions de fonctionnement : température de l'air et du processus
- Paramètres de charge : vitesse de rotation et couple
- Niveau d'usure de l'outil (Tool Wear [min])
- État de la machine : normal (0) ou défaillant (1)
- Type de défaillance : TWF, HDF, OSF, PWF, RNF

## Tableau des données et des défaillances

| Temp. Air (K) | Temp. Proc. (K) | Vitesse (rpm) | Couple (Nm) | Usure outil (min) | État machine | Type panne |
|---------------|-----------------|---------------|-------------|-------------------|--------------|------------|
| 298.1         | 308.6           | 1550          | 42.8        | 0                 | Normal       | Aucun      |
| 301.2         | 310.1           | 1400          | 55.2        | 120               | Défaillant   | TWF        |
| 299.5         | 309.0           | 1600          | 60.5        | 90                | Défaillant   | HDF        |
| 302.0         | 312.5           | 1300          | 70.1        | 200               | Défaillant   | OSF        |
| 297.8         | 307.9           | 1450          | 48.3        | 50                | Défaillant   | PWF        |
| 300.0         | 309.5           | 1500          | 45.0        | 30                | Défaillant   | RNF        |

## 1.7 Analyse Exploratoire des Capteurs

L'analyse exploratoire des données permet de visualiser la distribution des variables capteurs en fonction de l'état de la machine (normale vs défaillante). Les boîtes à moustaches suivantes illustrent ces distributions.




Figure 1 – Distribution de la température de l'air [K] en fonction de l'état de panne






Figure 2 – Distribution de la vitesse de rotation [rpm] en fonction de l'état de panne




Figure 3 – Distribution du couple [Nm] en fonction de l'état de panne




Figure 4 – Distribution de la température de processus [K] en fonction de l'état de panne




Figure 5 – Distribution de la température de l'air [K] – vue complémentaire

## Chapitre 2 : Simulation des Données et Modèles Statistiques

### 2.1 Principe de Simulation

Dans ce projet, des données représentatives du comportement d'une machine industrielle ont été simulées à partir des variables du dataset AI4I 2020 Predictive Maintenance Dataset. Ces variables incluent la température, la vitesse de rotation, le couple et l'usure de l'outil.

Les données de défaillance sont modélisées afin de reproduire le comportement réel de dégradation du système. L'évolution de l'état de la machine peut être représentée à travers des modèles statistiques permettant d'approcher le moment de la panne.

### 2.2 Censure des Données

Une censure à droite est introduite pour représenter les machines qui sont encore en fonctionnement au moment de l'observation, sans avoir atteint la défaillance. On distingue ainsi :

- Les machines défaillantes : état de panne observé, durée de vie connue
- Les machines censurées : fonctionnement toujours actif, durée de vie incomplète

### 2.3 Lois Statistiques de Défaillance

Les données de défaillance ont été simulées selon quatre lois statistiques classiquement utilisées en fiabilité industrielle :

- Loi de Weibull : modélise l'usure progressive des composants mécaniques
- Loi Exponentielle : modélise les défaillances à taux constant (phase de vie utile)
- Loi Log-normale : modélise la dégradation progressive avec dispersion
- Loi Gamma : modélise les sollicitations cumulatives et la fatigue



Figure 6 – Modèle de Weibull – Fonction de fiabilité




Figure 7 – Loi Exponentielle – Taux constant




Figure 8 – Loi Log-normale – Dégradation progressive




Figure 9 – Loi Gamma – Sollicitations cumulatives

## 2.4 Interprétation

- ▶ Les données simulées suivent une loi de Weibull adaptée aux systèmes industriels soumis à l'usure.
- ▶ L'introduction de la censure permet de représenter des équipements encore en fonctionnement à la fin de l'étude.
- ▶ Le dataset obtenu est cohérent avec un cadre PHM, combinant fiabilité (FMDS), diagnostic (classification) et pronostic (RUL).

## 2.5 Approche PHM (Prognostics and Health Management)

Le PHM est une approche de maintenance intelligente basée sur l'analyse des données afin de surveiller l'état du système, détecter les anomalies et prédire les pannes futures. Dans ce projet, l'approche PHM est appliquée selon trois axes :

- Diagnostic : identification de l'état de la machine (normal ou défaillant) à partir des variables capteurs en utilisant des modèles de classification supervisée.
- Pronostic : estimation de la durée de vie résiduelle (RUL) à partir de l'évolution des paramètres de fonctionnement et des modèles d'apprentissage automatique.
- Analyse de fiabilité (FMDS) : étude du comportement de la machine et des défaillances à partir des données, afin d'évaluer la performance globale du système industriel.

## Chapitre 3 : Analyse FMDS

### 3.1 Définition des Indicateurs FMDS

L'analyse FMDS permet d'évaluer la performance du système à travers quatre indicateurs principaux, définis comme suit :

| Indicateur     | Définition                                                                        |
|----------------|-----------------------------------------------------------------------------------|
| Fiabilité      | Probabilité qu'une machine fonctionne sans panne pendant une durée donnée         |
| Maintenabilité | Capacité à réparer rapidement une machine après défaillance                       |
| Disponibilité  | Probabilité qu'une machine soit opérationnelle à un instant donné                 |
| Sécurité       | Capacité du système à fonctionner sans risque pour l'environnement ou l'opérateur |

### 3.2 Formules et Calcul des Indicateurs

Les indicateurs sont calculés à partir des temps de fonctionnement et des événements de panne présents dans le dataset. Les formules utilisées sont les suivantes :

| Indicateur          | Formule                                                                | Description                                        |
|---------------------|------------------------------------------------------------------------|----------------------------------------------------|
| MTBF                | $MTBF = \Sigma(\text{temps de bon fonctionnement}) / \text{nb pannes}$ | Temps moyen entre deux pannes                      |
| MTTR                | $MTTR = \Sigma(\text{temps de réparation}) / \text{nb pannes}$         | Temps moyen de remise en service                   |
| Taux de défaillance | $\lambda = 1 / MTBF$                                                   | Fréquence des pannes par unité de temps            |
| Disponibilité       | $A = MTBF / (MTBF + MTTR)$                                             | Proportion du temps où le système est opérationnel |

### 3.3 Méthodologie Appliquée

La démarche suivie pour l'analyse FMDS est la suivante :

1. Extraction des observations de fonctionnement des machines
2. Identification des événements de panne (Target = 1)
3. Calcul des temps de fonctionnement entre pannes
4. Estimation des indicateurs FMDS (MTBF, MTTR,  $\lambda$ , A)
5. Visualisation et interprétation des résultats

### 3.4 Résultats Obtenus – Python

| Indicateur                        | Valeur          |
|-----------------------------------|-----------------|
| MTBF                              | 29.5 cycles     |
| MTTR                              | 1 cycle         |
| Taux de défaillance ( $\lambda$ ) | 0.0339          |
| Disponibilité (A)                 | 0.9672 (96.72%) |




Figure 10 – Indicateurs FMDS – Représentation graphique (Python)

### 3.5 Résultats Obtenus – MATLAB

| Indicateur                        | Valeur          |
|-----------------------------------|-----------------|
| MTBF                              | 29.36 cycles    |
| MTTR                              | 2 cycles        |
| Taux de défaillance ( $\lambda$ ) | 0.0341          |
| Disponibilité (A)                 | 0.9362 (93.62%) |

```

%----- MTBF, MTTR, lambda, availability -----

disp(MTBF);
disp(MTTR);
disp(failure_rate);
disp(availability);
    29.3609

    2

    0.0341

    0.9362

```

Figure 11 – Indicateurs FMDS – Résultats obtenus sous MATLAB

### 3.6 Interprétation des Résultats

- ▶ Le MTBF élevé ( $\approx 29$  cycles) indique que la machine fonctionne pendant une longue période avant l'apparition d'une panne : bonne fiabilité globale.
- ▶ Le MTTR faible (1–2 cycles) indique une maintenance rapide et efficace après chaque défaillance.
- ▶ Le taux de défaillance faible ( $\lambda \approx 0.034$ ) confirme que les pannes sont peu fréquentes.
- ▶ La disponibilité élevée (93–97%) confirme que le système est opérationnel la grande majorité du temps.

## Chapitre 4 : Analyse de Survie

### 4.1 Méthodes Non Paramétriques

L'analyse de survie est utilisée pour estimer la probabilité de fonctionnement d'un équipement au fil du temps, en tenant compte de la censure des données. Plusieurs méthodes ont été appliquées :

- Kaplan-Meier : estimation de la probabilité de survie dans le temps, prend en compte la censure, très utilisée en fiabilité industrielle.
- Nelson-Aalen : estime le risque cumulatif de défaillance et permet de suivre l'évolution du risque dans le temps.
- Fleming-Harrington : variante améliorée de Nelson-Aalen, donne une estimation plus stable du hazard.
- Kernel Smoothing : lissage de la fonction de risque pour obtenir une courbe continue du taux de défaillance.




Figure 12 – Courbe de fiabilité – Estimateur de Kaplan-Meier






Figure 13 – Fonction de survie – Modèle de Weibull




Figure 14 – Risque cumulatif – Estimateur de Nelson-Aalen

## 4.2 Modèle de Weibull – Analyse Paramétrique

Le modèle de Weibull a été utilisé afin d'étudier l'évolution du taux de défaillance du système étudié. Les paramètres estimés sont les suivants :

```

=== RESULTATS WEIBULL ===
Lambda (scale): 487.51643628075743
Rho (shape): 2.6120338394203397

```

Figure 15 – Paramètres du modèle de Weibull

| Paramètre                     | Valeur | Interprétation                                                 |
|-------------------------------|--------|----------------------------------------------------------------|
| Lambda ( $\lambda$ – échelle) | 487.52 | Durée de vie caractéristique du système                        |
| Rho ( $\rho$ – forme)         | 2.61   | Défaillance par usure ( $\rho > 1 \rightarrow$ taux croissant) |

### 4.3 Interprétation du Modèle de Weibull

Le paramètre de forme ( $\rho = 2.61 > 1$ ) indique que le système suit un mode de défaillance par usure. Cela signifie que les défaillances augmentent progressivement avec le temps sous l'effet du vieillissement des composants.

Le modèle de Weibull permet de distinguer trois phases principales :

- Phase initiale : fonctionnement stable avec une forte fiabilité (0 à ~200 cycles)
- Phase intermédiaire : dégradation progressive des performances (~200 à ~400 cycles)
- Phase critique : augmentation rapide du taux de défaillance (au-delà de ~487 cycles)

► Le paramètre d'échelle ( $\lambda \approx 487.52$ ) définit la durée de vie caractéristique : au-delà, la probabilité de défaillance augmente fortement.

► Ce comportement est typique des systèmes industriels soumis à un fonctionnement continu et à l'usure mécanique.

# Chapitre 5 : Diagnostic des Défaillances par Machine Learning

## 5.1 Objectif du Diagnostic

Dans le cadre du projet de maintenance prédictive basé sur le dataset AI4I 2020, la phase de diagnostic constitue une étape essentielle de l'approche PHM. Elle vise à identifier automatiquement l'état de fonctionnement des machines à partir des données issues des capteurs. L'objectif principal est de développer un modèle de classification capable de distinguer :

- Classe 0 : Normal – fonctionnement sain
- Classe 1 : Failure – défaillance détectée

## 5.2 Modèles de Machine Learning Utilisés

### Random Forest Classifier

Modèle d'ensemble basé sur plusieurs arbres de décision entraînés sur des sous-ensembles aléatoires des données. Il présente les avantages suivants : très performant pour les données complexes, robuste face au bruit et aux valeurs aberrantes, bonne capacité de généralisation. Avantage principal : haute précision globale et stabilité des résultats.

### Decision Tree

Modèle basé sur une structure d'arbre de décision simple. Facile à interpréter et permet de visualiser les règles de décision. Utilisé comme modèle de référence. Limite : risque de surapprentissage sur les données d'entraînement.

### Support Vector Machine (SVM)

Algorithme basé sur la séparation optimale des classes par un hyperplan de marge maximale. Efficace pour les problèmes de classification binaire avec bonne capacité de généralisation dans certains cas. Limite : moins performant sur les données déséquilibrées.

## 5.3 Résultats des Modèles – Python

| Modèle        | Accuracy | Precision (panne) | Recall (panne) | F1-score |
|---------------|----------|-------------------|----------------|----------|
| Random Forest | 98%      | 0.85              | 0.36           | 0.51     |
| Decision Tree | 97%      | 0.80              | 0.32           | 0.46     |
| SVM           | 97.2%    | 0.83              | 0.22           | 0.35     |

|                 |           |        |          |         |
|-----------------|-----------|--------|----------|---------|
| ◆ SVM           |           |        |          |         |
| Accuracy: 0.972 |           |        |          |         |
|                 | precision | recall | f1-score | support |
| 0               | 0.97      | 1.00   | 0.99     | 1932    |
| 1               | 0.83      | 0.22   | 0.35     | 68      |
| accuracy        |           |        | 0.97     | 2000    |
| macro avg       | 0.90      | 0.61   | 0.67     | 2000    |
| weighted avg    | 0.97      | 0.97   | 0.96     | 2000    |

Figure 16 – Résultats du modèle SVM – Rapport de classification




Figure 17 – Matrice de confusion – Random Forest Classifier

## 5.4 Résultats – MATLAB

Le modèle de classification implémenté sous MATLAB (Decision Tree via `fitctree`) a permis de détecter les états de fonctionnement de la machine avec une accuracy de 98%, confirmant la robustesse de l'approche.




Figure 18 – Matrice de confusion – Modèle de classification MATLAB

## 5.5 Analyse de l'Importance des Variables (Feature Importance)

L'analyse de l'importance des variables permet d'identifier les capteurs les plus influents dans la prédiction des défaillances. Le modèle Random Forest calcule automatiquement un score d'importance pour chaque variable en fonction de sa contribution à la réduction de l'erreur de classification.




Figure 19– Scores d'importance des variables (Random Forest)

- ▶ Torque [Nm] → 0.3286 : variable la plus influente dans la prédiction des défaillances
- ▶ Rotational speed [rpm] → 0.2198 : deuxième facteur le plus important
- ▶ Tool wear [min] → 0.1604 : usure de l'outil, facteur mécanique critique
- ▶ Air temperature [K] → 0.1492 : facteur thermique secondaire
- ▶ Process temperature [K] → 0.1420 : facteur thermique complémentaire

## 5.6 Interprétation des Résultats

Le modèle Random Forest offre les meilleures performances globales en termes de précision (98%). Cependant, l'analyse détaillée révèle une limitation importante : le recall faible (0.36) indique que plusieurs pannes réelles ne sont pas détectées. Cela s'explique par le fort déséquilibre entre les classes (environ 97% normal vs 3% défaillant).

- ▶ Le Random Forest offre la meilleure précision globale avec une accuracy de 98%.
- ▶ Le Decision Tree assure une bonne interprétabilité des résultats grâce à sa structure arborescente.
- ▶ Le SVM est moins performant pour la détection des pannes en raison du déséquilibre des données.
- ▶ Les variables mécaniques (Torque, Tool wear) sont les plus critiques dans la prédiction des pannes.

## Chapitre 6 : Pronostic de la Durée de Vie Résiduelle (RUL)

### 6.1 Introduction au Pronostic

Le pronostic constitue une étape centrale dans l'approche PHM. Il vise à estimer la durée de vie restante (Remaining Useful Life – RUL) d'un équipement industriel afin d'anticiper les défaillances et optimiser les stratégies de maintenance. Dans ce projet basé sur le dataset AI4I 2020, le RUL représente le temps restant avant la défaillance de la machine en fonction de son état d'usure et de ses conditions de fonctionnement.

### 6.2 Modèle Utilisé – XGBoost Regressor

Pour la prédiction du RUL, un modèle de régression basé sur XGBoost Regressor a été utilisé. Ce modèle est particulièrement adapté car :

- Il capture efficacement les relations non linéaires complexes entre les capteurs
- Il offre une excellente capacité de généralisation sur des données non vues
- Il est performant sur les données industrielles bruitées
- Il améliore la précision par apprentissage progressif (boosting itératif)

### 6.3 Méthodologie

Les étapes suivies pour le pronostic sont les suivantes :

6. Sélection des variables explicatives : température de l'air, température du processus, vitesse de rotation, couple, usure de l'outil, features de dégradation (rolling + trends)
7. Construction de la variable cible (RUL simulé amélioré)
8. Prétraitement et normalisation des données
9. Séparation training / testing (80% / 20%)
10. Entraînement du modèle XGBoost Regressor
11. Prédiction de la durée de vie restante et évaluation des performances

### 6.4 Résultats Obtenus

| Métrique       | Valeur | Interprétation                                       |
|----------------|--------|------------------------------------------------------|
| RMSE           | 3.23   | Erreur quadratique moyenne faible – bonne précision  |
| MAE            | 1.76   | Erreur absolue moyenne réduite – prédictions fiables |
| R <sup>2</sup> | 0.937  | Le modèle explique plus de 93% de la variance du RUL |




Figure 20– RUL réel vs RUL prédit – Modèle XGBoost Regressor

## 6.5 Interprétation des Résultats

- ▶ Un RMSE de 3.23 indique que l'erreur moyenne de prédiction est très faible par rapport à la plage de valeurs du RUL.
- ▶ Un MAE de 1.76 confirme une faible erreur absolue sur les prédictions individuelles.
- ▶ Un  $R^2$  de 0.937 montre que le modèle XGBoost explique plus de 93% de la variance de la durée de vie résiduelle.
- ▶ La dispersion des points autour de la droite idéale est minimale, confirmant la robustesse du modèle.

## 6.6 Importance Industrielle du Pronostic RUL

Le pronostic du RUL apporte des bénéfices concrets pour la maintenance industrielle :

- Planifier les interventions de maintenance avant la panne, évitant les arrêts imprévus
- Réduire les coûts de maintenance en évitant les remplacements prématurés ou tardifs
- Optimiser la gestion des stocks de pièces de rechange
- Améliorer la disponibilité et la fiabilité globale des équipements

### Limites et perspectives

Cette étude présente certaines limites liées principalement à la nature simulée des données ainsi qu'au déséquilibre des classes, ce qui peut influencer la performance des modèles de classification et réduire la capacité de généralisation en contexte industriel réel.

Dans un environnement industriel réel, l'intégration de capteurs IoT en temps réel permettrait une collecte continue de données plus représentatives des conditions d'exploitation.

Par ailleurs, l'utilisation de modèles avancés de Deep Learning tels que les réseaux LSTM ou les Transformers pourrait améliorer significativement la précision du diagnostic et du



pronostic, notamment pour la modélisation des dépendances temporelles et la prédiction de la durée de vie résiduelle (RUL).

Enfin, une amélioration du rééquilibrage des classes (SMOTE, data augmentation) et l'intégration de données multi-sources renforceraient la robustesse du système.

## Conclusion Générale

Ce projet s'inscrit dans le domaine de la maintenance prédictive et du PHM (Prognostics and Health Management), dont l'objectif principal est d'améliorer la fiabilité et la disponibilité des équipements industriels en anticipant les défaillances.

Une approche complète a été développée en combinant deux axes principaux : le diagnostic des défaillances, basé sur un modèle de classification Random Forest permettant de détecter l'état de la machine avec une précision globale de 98%, et le pronostic de la durée de vie restante (RUL), basé sur un modèle XGBoost permettant d'estimer le temps restant avant panne avec un  $R^2$  supérieur à 0.93.

L'analyse FMDS a permis de quantifier les indicateurs de fiabilité du système : un MTBF d'environ 29 cycles, un taux de défaillance de 0.034 et une disponibilité supérieure à 93%, confirmant la bonne performance globale du système industriel.

L'analyse de survie par les méthodes de Kaplan-Meier, Nelson-Aalen et le modèle de Weibull a révélé que le système suit un comportement de défaillance par usure ( $\rho = 2.61 > 1$ ), avec une durée de vie caractéristique de 487 cycles.

L'analyse de l'importance des variables a montré que les paramètres mécaniques – notamment le couple (Torque) et l'usure de l'outil (Tool wear) – sont les facteurs les plus déterminants dans la prédiction des défaillances, confirmant le rôle clé de la surveillance de ces capteurs.

- |                                                                                                        |
|--------------------------------------------------------------------------------------------------------|
| ► Diagnostic : Random Forest – Accuracy 98% – détection fiable de l'état machine                       |
| ► Pronostic : XGBoost – RMSE 3.23, MAE 1.76, $R^2$ 0.937 – estimation précise du RUL                   |
| ► Fiabilité : MTBF $\approx$ 29 cycles, Disponibilité $>$ 93% – bonne performance globale              |
| ► Weibull : $\rho = 2.61$ (usure), $\lambda \approx 487$ cycles – durée de vie caractéristique établie |
| ► Variables critiques : Torque [Nm] et Tool wear [min] dominant la prédiction des pannes               |

En conclusion, ce projet démontre que l'intégration des méthodes de diagnostic et de pronostic dans une approche PHM constitue une solution efficace pour optimiser les stratégies de maintenance, réduire les arrêts imprévus et améliorer la performance globale des systèmes industriels. L'exploitation intelligente des données capteurs, combinée aux techniques de machine learning, ouvre des perspectives prometteuses pour le développement de systèmes de maintenance prédictive de nouvelle génération.

## Annexe – Code Python (Extraits)

```
import pandas as pd
```

```
import numpy as np
```

```
from sklearn.model_selection import train_test_split
```

```
from sklearn.ensemble import RandomForestClassifier
```

```
from sklearn.metrics import accuracy_score, classification_report
```

```
import seaborn as sns
```

```
import matplotlib.pyplot as plt
```

```
# =====
```

```
# 1. Chargement des données
```

```
# =====
```

```
df = pd.read_csv("ai4i2020.csv")
```

```
print("Dataset shape:", df.shape)
```

```
print(df.head())
```

```
# =====
```

```
# 2. FMDS Calculation
```

```
# =====
```

```
total = len(df)
```

```
failures = df['Target'].sum()
```

```
MTBF = total / failures
```

```
MTTR = 1 # hypothèse industrielle
```

```
failure_rate = failures / total
```

```
availability = MTBF / (MTBF + MTTR)
```

```
print("\n=== FMDS RESULTS ===")
```

```
print("MTBF:", MTBF)
```

```
print("MTTR:", MTTR)
```

```
print("Failure Rate:", failure_rate)
```

```
print("Availability:", availability)
```

```
# =====
```

```

# 3. Data preparation
# =====
X = df.drop(columns=['Target'])
y = df['Target']

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

# =====
# 4. Random Forest Model
# =====
model = RandomForestClassifier(
    n_estimators=200,
    random_state=42,
    class_weight='balanced'
)

model.fit(X_train, y_train)

y_pred = model.predict(X_test)

# =====
# 5. Evaluation
# =====
accuracy = accuracy_score(y_test, y_pred)

print("\n=== MODEL RESULTS ===")
print("Accuracy:", accuracy)
print(classification_report(y_test, y_pred))

# =====
# 6. Feature Importance
# =====
importances = model.feature_importances_

```

```
features = X.columns

feat_imp = pd.DataFrame({
    'Feature': features,
    'Importance': importances
}).sort_values(by='Importance', ascending=False)

print("\n=== FEATURE IMPORTANCE ===")
print(feat_imp)

plt.figure(figsize=(8,5))
sns.barplot(x='Importance', y='Feature', data=feat_imp)
plt.title("Feature Importance - Random Forest")
plt.show()
```